

Segmentación de distritos del Perú según movilidad y salida escolar en primaria y secundaria (2023-2024)



Integrantes:

Rosalinda Salva Vasquez
Cristina Nevado Perez

Curso:

Data Mining

Profesora:

Soledad Espezua Llerena

Lima, Setiembre 2026

1. Formulación refinada

1.1. Planteamiento del problema

En el Perú, la pérdida de estudiantes del sistema escolar (2023–2024) no ocurre por igual en todo el territorio: mientras los promedios globales muestran estabilidad, en realidad ocultan brechas severas en distritos vulnerables donde muchos alumnos dejan de matricularse de un año a otro. Dado que los registros oficiales solo contabiliza la salida interanual sin registrar los motivos detrás de este corte de matrícula, y que la información está fragmentada entre escuelas y distritos, a las autoridades locales les resulta difícil identificar a tiempo qué distritos concentran la mayor fuga para priorizar acciones de retención.

1.2. Usuario/beneficio

Ministerio de Educación del Perú (MINEDU), Direcciones Regionales de Educación (DRE), Unidades de Gestión Educativa Local (UGEL) y analistas de políticas públicas educativas.

1.3. Objetivo de análisis

El objetivo de este proyecto es integrar cuatro fuentes públicas del sector Educación del Perú en una única base de datos de análisis a nivel de distrito y nivel educativo. Para ello, se utilizará el Padrón de Instituciones Educativas (Padron.dbf) como tabla puente que permita vincular la información de matrícula, disponible a nivel de institución educativa, con los indicadores de deserción, reportados a nivel de distrito (UBIGEO). A partir de esta integración, se busca comparar las tasas de movimientos de estudiantes entre primaria y secundaria a escala distrital e identificar qué territorios presentan las mayores brechas.

2. Fuentes y unidad de análisis

2.1. Fuentes actualizadas y reproducibles

Los datos provienen del Portal de Datos Abiertos del Gobierno del Perú (datosabiertos.gob.pe) y de la plataforma ESCALE del MINEDU. Se utilizó el archivo: Padron.dbf como catálogo oficial de colegios y su ubicación distrital ([Censo Escolar - ESCALE - Unidad de Estadística Educativa](#)); el archivo Matriculación_y_Trayectoria_Estudiantil_2023.csv con microdatos de matrícula y situación académica por institución ([Matriculación y Trayectoria Estudiantil 2021-2024 | Plataforma Nacional de Datos Abiertos](#)) y los conjuntos Tasa_y_número_de_desertores_en_Educación Primaria_2023-2024.csv y Tasa_y_número_de_desertores_en_Educación Secundaria_2023-2024.csv para obtener las medidas oficiales de deserción interanual por cohorte a nivel distrital ([Tasa y número de desertores en Educación Primaria y Secundaria 2023/2024 | Plataforma Nacional de Datos Abiertos](#))

2.2. Definición qué representa cada fila de la base integrada (unidad de análisis) y de la matriz analítica

Distrito por nivel educativo (o distrito-nivel). Cada registro representa el comportamiento educativo de un distrito específico en un nivel formativo determinado (Primaria o Secundaria).

3. Diagnóstico y tratamiento de calidad

3.1. Duplicados

Revisamos duplicados en dos niveles: por columna individual y por fila completa. Encontramos que, a nivel de columna, hay muchos valores repetidos (esperado, ya que columnas como gestion, D_GESTION o dsc_nivel tienen pocas categorías posibles). Sin embargo, al revisar filas completamente duplicadas, ninguna de las cuatro fuentes presentó duplicados exactos: padron (0 de 8,627), matricula_2023 (0 de 114,832), desercion_primaria (0 de 1,890) y desercion_secundaria (0 de 1,846). Esto confirma que cada fila representa un registro único (escuela, estudiante agregado o distrito, según la fuente).

Figura 1

Duplicados exactos por fuente

```
import pandas as pd

# 1. Recopilar los duplicados exactos por fuente
datos_resumen = []

for nombre, df in [("padron", padron), ("matricula_2023", matricula_2023),
                  ("desercion_primaria", desercion_primaria),
                  ("desercion_secundaria", desercion_secundaria)]:

    n_dup = df.duplicated().sum()

    datos_resumen.append({
        "Fuente": nombre,
        "Filas Duplicadas Exactas": n_dup,
        "Total de Filas": len(df)
    })

# Convertir a DataFrame global
df_duplicados_exactos = pd.DataFrame(datos_resumen)

# Mostrar la tabla con formato claro y separador de miles
display(
    df_duplicados_exactos.style
    .format({"Filas Duplicadas Exactas": "{:,}", "Total de Filas": "{:,}"})
    .hide(axis="index")
)
```

Tabla resumen de duplicados

Fuente	Filas Duplicadas Exactas	Total de Filas
padron	0	8,627
matricula_2023	0	114,832
desercion_primaria	0	1,890
desercion_secundaria	0	1,846

Nota. Elaboración propia con Python (pandas).

3.2. Faltantes

La mayoría de las fuentes no presenta valores faltantes relevantes. En padron, solo la columna TALUMNO tiene 1 nulo de 8,627 filas. En matricula_2023, varias columnas numéricas (TotalEstudiantes, Aprobado, Retirado, etc.) tienen apenas 1 nulo, salvo TipoDiscaIntegrada, con 96,814 nulos — pero este no es un dato faltante real: la columna solo se llena cuando Discapacidad > 0, por lo que el vacío representa "sin discapacidad registrada", no un error de captura. Las fuentes de deserción (desercion_primaria y desercion_secundaria) no presentan ningún valor nulo.

Figura 2

Tablas resumen de nulos por fuentes

padron			desercion_primaria			desercion_secundaria		
	index	Nulos		index	Nulos		index	Nulos
0	COD_MOD	0	0	ubigeo	0	0	ubigeo	0
1	ANEXO	0	1	Departamento	0	1	Departamento	0
2	NIV_MOD	0	2	Provincia	0	2	Provincia	0
3	D_NIV_MOD	0	3	Distrito	0	3	Distrito	0
4	CODGEO	0	4	desertor	0	4	desertor	0
5	DPTO	0	5	denominador	0	5	denominador	0
6	PROV	0	6	Tasa	0	6	Tasa	0
7	DIST	0						
8	D_GESTION	0						
9	D_COD_TUR	0						
10	CEN_EDU	0						
11	DRE_UGEL	0						
12	TALUMNO	1						
13	AREA_CENSO	0						
14	DAREACENSO	0						

Nota. Elaboración propia con Python (pandas).

3.3. Valores imposibles o atípicos e inconsistencias relevantes.

Ya en la base integrada (base_final), confirmamos que no quedan valores nulos en ninguna columna tras el proceso de integración. Para detectar valores atípicos aplicamos la regla del rango intercuartílico (IQR) sobre las variables numéricas clave: encontramos 12.5% de outliers en total_estudiantes_2023, 17.26% en n_desertores, 6.94% en tasa_desercion_pct y 6.55% en n_escuelas_2023. Sin embargo, no los tratamos como errores: distritos con valores muy altos en estas variables suelen corresponder a distritos urbanos grandes (por ejemplo, capitales de provincia), es decir, reflejan heterogeneidad real entre distritos y no problemas de calidad de datos. Por eso decidimos conservarlos en el análisis, en vez de eliminarlos.

Figura 3

Detección de outlier con la regla de rango intercuartílico (IQR)

```
# Outliers con la regla de rango intercuartílico (IQR)
def resumen_outliers_iqr(serie, nombre):
    q1, q3 = serie.quantile([0.25, 0.75])
    iqr = q3 - q1
    lim_inf, lim_sup = q1 - 1.5*iqr, q3 + 1.5*iqr
    n_outliers = ((serie < lim_inf) | (serie > lim_sup)).sum()
    return {
        "variable": nombre, "Q1": round(q1,2), "Q3": round(q3,2),
        "limite_inferior": round(lim_inf,2), "limite_superior": round(lim_sup,2),
        "n_outliers": n_outliers, "pct_outliers": round(100*n_outliers/len(serie),2)
    }

variables_numericas = ["total_estudiantes_2023", "n_desertores", "tasa_desercion_pct", "n_escuelas_2023"]
resumen_out = pd.DataFrame([resumen_outliers_iqr(base_final[v], v) for v in variables_numericas])
display(resumen_out)
```

Tabla de análisis estadístico de valores atípicos (outliers)

	variable	Q1	Q3	limite_inferior	limite_superior	n_outliers	pct_outliers
0	total_estudiantes_2023	66.0	524.50	-621.75	1212.25	63	12.50
1	n_desertores	0.0	9.25	-13.88	23.12	87	17.26
2	tasa_desercion_pct	0.0	1.32	-1.98	3.30	35	6.94
3	n_escuelas_2023	1.0	6.00	-6.50	13.50	33	6.55

Nota. Elaboración propia con Python (pandas).

4. Integración

4.1. Tablas integradas

- Padron.dbf (Catálogo oficial y tabla puente que dota de geografía a cada escuela).

- Matriculación_y_Trayectoria_Estudiantil_2023.csv (Matrícula y rendimiento por escuela en 2023, filtrada a Primaria y Secundaria).
- Tasa_y_número_de_desertores_en_Educación Primaria_2023-2024.csv y
- Tasa_y_número_de_desertores_en_Educación Secundaria_2023-2024.csv (Reconceptualizadas analíticamente como tasas y volúmenes de movilidad y salida interanual de estudiantes entre 2023 y 2024).

4.2. Claves

- Nivel Escuela (Nivel 1): `cod_mod_key` + `anexo_key` + `id_nivel` (Matrícula emparejado con el Padrón).
- Nivel Distrito (Nivel 2): `ubigeo_key` + `dsc_nivel` (Matrícula agregada a nivel distrital) emparejado con los reportes distritales de movilidad.

4.3. Cardinalidades y relaciones

- Nivel Escuela: (1:1) a través de la clave compuesta (``cod_mod_key`` + ``anexo_key`` + ``id_nivel``), donde cada servicio educativo activo en la matrícula se asocia unívocamente con su registro geoespacial en el catálogo oficial de instituciones educativas.
- Nivel Distrito: (1:1) entre la Matrícula agregada distrital y los reportes de movilidad mediante la clave compuesta (`ubigeo_key` + `dsc_nivel`), vinculando de manera única el total territorial con su correspondiente tasa y volumen de salida escolar para cada nivel educativo.

4.4. Tipos de unión

- Unión izquierda (`how="left"`) para el cruce Matrícula ↔ Padrón (preservando los registros e identificando mermas).
- Unión externa (`how="outer"`) para consolidar la matriz analítica distrital final.

4.5. Granularidad

- **Distrito por Nivel Educativo** (cada fila de la base integrada representa un distrito individual del Perú, registrando simultáneamente sus métricas para primaria y secundaria).

4.6. Validación de registros

- Nivel 1 (Escuela): 392,095 registros de matrícula emparejados exitosamente con el padrón (~99.74%), y 1,010 registros no emparejados (`left_only`) debido a discrepancias de códigos modulares.
- Nivel 2 (Distrito): Cobertura de 3,730 registros distritales integrados exitosamente (~99.84%), con apenas 6 discordancias menores excluidas por inconsistencias geográficas.

Figura 4

Integración auditada, Nivel 1: cruce entre matrícula y padrón

```

matricula_geo = matricula.merge(
    padron[["cod_mod_key", "anexo_key", "NIV_MOD", "D_NIV_MOD", "CODGEO", "ubigeo_key",
            "DPTO", "PROV", "DIST", "D_GESTION", "DRE_UGEL", "AREA_CENSO", "DAREACENSO"]],
    left_on=["cod_mod_key", "anexo_key", "id_nivel"],
    right_on=["cod_mod_key", "anexo_key", "NIV_MOD"],
    how="left",
    indicator=True
)

conteo_cruce_1 = matricula_geo["_merge"].value_counts().reset_index()
conteo_cruce_1.columns = ["resultado_cruce", "cantidad"]
display(conteo_cruce_1)

```

Integración auditada, Nivel 2: cruce entre la base distrital y deserción

```

base_validacion_2 = base_distrital.merge(
    desercion[["ubigeo_key", "dsc_nivel", "n_desertores", "n_matriculados_base_desercion", "tasa_desercion_pct"]],
    on=["ubigeo_key", "dsc_nivel"],
    how="outer",
    indicator=True,
    suffixes=("_matricula", "_desercion")
)

conteo_cruce_2 = base_validacion_2["_merge"].value_counts().reset_index()
conteo_cruce_2.columns = ["resultado_cruce", "cantidad"]
conteo_cruce_2["porcentaje"] = 100 * conteo_cruce_2["cantidad"] / conteo_cruce_2["cantidad"].sum()
display(conteo_cruce_2)

```

Nota. Elaboración propia con Python (pandas). Unión externa (how="outer") con indicador de cruce sobre las llaves ubigeo_key y dsc_nivel, utilizada para validar la cobertura antes de construir la base final

5. EDA e Interpretación

a. Barras: Total de estudiantes matriculados por gestión y nivel

Hallazgos: En 2023, la mayor cantidad de estudiantes matriculados se concentra en las instituciones públicas de gestión directa, con 1 287 271 estudiantes en Primaria y 440 939 en Secundaria. En la gestión privada, se registran 104 104 matriculados en Primaria y 59 914 en Secundaria. Por otro lado, las instituciones públicas de gestión privada presentan 36 982 estudiantes en Primaria y 35 378 en Secundaria.


b. Top 10 distritos con mayor tasa de movilidad/salida escolar(2023)

Hallazgos: La mayor tasa de salida escolar se concentra en el distrito de Teniente Manuel Clavero (Loreto), con una tasa combinada de 25.78% (13.30% y 12.48%). Le siguen con valores críticos los distritos de San Cristóbal (Moquegua) con 18.64%, Ataquero (Áncash) con 17.43%, Huachupampa (Lima) con 14.29% y Culebras (Áncash) con 14.08%. Con tasas intermedias dentro del top se ubican Manas (Lima) con 12.82%, La Cuesta (La Libertad) con 12.77% y Aguas Verdes (Tumbes) con 12.76%. Por

otro lado, el distrito que presenta la menor tasa dentro de este grupo es Mache (La Libertad) con 12.00%.

Figura 5

Top 10 distritos con mayor tasa de movilidad o salida escolar (2023)



Nota. Elaboración propia con Python (Plotly), a partir de la base integrada (base_final).

6. Transformación de variables

6.1. Codificación

Codificamos dsc_nivel como variable binaria (nivel_bin), asignando 0 a Primaria y 1 a Secundaria, dado que al tener únicamente dos categorías no es necesario aplicar one-hot encoding.

6.2. Variables derivadas

Creamos cuatro variables derivadas a partir de los totales de la matrícula 2023: el porcentaje de aprobados (pct_aprobados), el porcentaje de desaprobados (pct_desaprobados), el porcentaje de retirados (pct_retirados) y el número de estudiantes por escuela (estudiantes_por_escuela), este último como indicador del tamaño promedio de las instituciones educativas en cada distrito.

Figura 6

Cálculo de variables derivadas: porcentajes de aprobación, desaprobados, retirados y estudiantes por escuela

```
base_final["pct_aprobados"] = base_final["total_aprobados_2023"] / base_final["total_estudiantes_2023"]
base_final["pct_desaprobados"] = base_final["total_desaprobados_2023"] / base_final["total_estudiantes_2023"]
base_final["pct_retirados"] = base_final["total_retirados_2023"] / base_final["total_estudiantes_2023"]
base_final["estudiantes_por_escuela"] = base_final["total_estudiantes_2023"] / base_final["n_escuelas_2023"]
```

Nota. Elaboración propia con Python (pandas), a partir de los totales de matrícula 2023 (base_final).

7. Matriz analítica

7.1 Variables incluidas, representación final y exclusiones importante**

Para la matriz analítica incluimos las variables `ubigeo_key`, `DPTO`, `DIST`, `nivel_bin`, `pct_aprobados`, `pct_desaprobados`, `pct_retirados`, `tasa_desercion_pct` y `estudiantes_por_escuela`. Excluimos los totales absolutos (como `total_estudiantes_2023`) y el desglose por tipo de gestión, ya que el análisis se centra en la comparación entre distritos a partir de tasas y proporciones, no de volúmenes ni de la composición pública/privada de cada uno.

Figura 7

Creación de la matriz analítica

```
matriz_analitica = base_final[["ubigeo_key", "DPTO", "DIST", "nivel_bin", "pct_aprobados", "pct_desaprobados", "pct_retirados", "tasa_desercion_pct", "estudiantes_por_escuela"]].copy()

display(matriz_analitica.head())
```

Matriz analítica.

ubigeo_key	DPTO	DIST	nivel_bin	pct_aprobados	pct_desaprobados	pct_retirados	tasa_desercion_pct	estudiantes_por_escuela
10101	AMAZONAS	CHACHAPOYAS	0	0.988947062	0.00814427	0.0017452	0.410033767	191
10101	AMAZONAS	CHACHAPOYAS	1	0.979228487	0.017210682	0.00296736	1.227711196	842.5
10102	AMAZONAS	ASUNCION	0	1	0	0	0	4
10103	AMAZONAS	BALSAS	0	0.951048951	0.048951049	0	0	23.83333333
10104	AMAZONAS	CHETO	0	0.926829268	0.073170732	0	0	20.5
10105	AMAZONAS	CHILQUIN	0	0.962962963	0.037037037	0	4.838709677	9
10106	AMAZONAS	CHUQUIBAMBA	0	0.901408451	0.098591549	0	1.544401544	17.75

Nota. Elaboración propia con Python (pandas), a partir de los totales de matrícula 2023 (`base_final`).

7.2 Discretización o escalamiento solo cuando correspondan y estén justificados

Creamos una copia de la matriz analítica para escalarla con z-score, como paso previo al modelo de clustering. Optamos por z-score en lugar de Min-Max porque nuestras variables presentan valores atípicos (por ejemplo, distritos con `estudiantes_por_escuela` muy altos), y z-score es menos sensible a estos que Min-Max, que comprimiría el resto de los datos hacia un rango muy estrecho.

8. Próximo paso

Dado que el objetivo es segmentar los distritos según patrones de movilidad de estudiantes, aplicaremos K-Means, un método de clustering basado en centroides que agrupa las observaciones minimizando la distancia entre cada punto y el centro de su cluster. Para ello, utilizaremos la matriz analítica ya estandarizada.

9. Repositorio del Proyecto

<https://github.com/canevadop-dev/proyecto-datamining>