Distritos del Perú con mayor salida escolar: un análisis de agrupamiento (2023–2024)

Rosalinda Salva, Cristina Nevado
Curso: Data Mining
Universidad del Pacífico
Docente: Soledad Espezúa Llerena

***Resumen*—Los promedios nacionales de matrícula escolar ocultan distritos donde muchos estudiantes dejan de matricularse de un año a otro. Este avance integra cuatro fuentes públicas del sector Educación (Padrón de IIEE, matrícula 2023 y deserción 2023–2024 en primaria y secundaria) en una matriz de 3 730 observaciones distrito × nivel descritas por cinco variables. Se aplicó *log1p* y z-score, y se compararon tres técnicas: K-means, DBSCAN y clustering jerárquico aglomerativo (Ward). K-means y Ward producen dos grupos similares (84.6 % de coincidencia): uno de salida escolar baja y otro de salida alta, con escuelas más grandes y mayor presencia de secundaria. DBSCAN forma un único grupo y solo detecta casos extremos. Los datos forman una nube continua, por lo que los resultados son una segmentación por perfiles. Silhouette y Davies-Bouldin quedan pendientes.**

***Index Terms*—data mining, clustering jerárquico, salida escolar, GeoPandas**

I. Introducción

El proyecto usa datos abiertos del MINEDU sobre matrícula y deserción en primaria y secundaria entre 2023 y 2024, por distrito. Cada año, algunos estudiantes no vuelven a matricularse en ninguna escuela, lo que interrumpe su educación básica. Este problema no se reparte por igual: el promedio nacional parece estable, pero oculta distritos donde la salida es mucho mayor, y hoy no es claro dónde se concentra ni si pesa más en primaria o en secundaria. El usurio o beneficiario de este proyecto es: El MINEDU, las Direcciones Regionales de Educación (DRE) y las UGEL, que deciden dónde destinar becas, transporte, tutorías y seguimiento de estudiantes en riesgo, y necesitan saber qué distritos y qué nivel priorizar. Nuestro objetivo de analisis es agrupar los distritos según su perfil de salida escolar y comparar primaria con secundaria, para ubicar los de mayor salida. **Pregunta principal.** *¿Qué perfiles de distritos se distinguen según su salida escolar y dónde están los de mayor salida en cada nivel?*

II. Datos y representación final

Fuentes: Padrón de IIEE (aporta el ubigeo de cada escuela), matrícula 2023 y deserción 2023–2024 de primaria y secundaria, medida como cohorte (matriculados en 2023 que no volvieron a matricularse en 2024 en ninguna escuela del sistema). **Unidad de análisis:** distrito × nivel educativo (3 730 observaciones). **Variables principales:** % desaprobados, % retirados, % con discapacidad, tasa de deserción y estudiantes por escuela. **Representación final:** matriz de 3 730×5 sin nulos, con *log1p* y z-score para reducir la asimetría (sesgo de 1.88–3.94 a $-0{,}12$–1.38) y evitar que una variable domine la distancia. **Exclusiones:** identificadores, totales absolutos (se comparan tasas), % aprobados (colineal) y `nivel_bin`, usado solo para interpretar.

III. Metodología

Como no existe una clase que indique qué distritos son críticos, se usó agrupamiento no supervisado. La técnica principal es el **clustering jerárquico con enlace Ward** no exige fijar el número de grupos de antemano y forma grupos compactos. Se contrastó con **K-means** y **DBSCAN**. Se ejecutaron con `scikit-learn` sobre los datos reales, sin usar coordenadas ni `nivel_bin`.

Supuestos y limitaciones. Las tres técnicas usan distancia euclidiana, por lo que la escala importa; se prefirió z-score sobre Min-Max porque los valores extremos son reales y Min-Max comprimiría a la mayoría. Ward y K-means asumen grupos compactos y son sensibles a valores extremos; DBSCAN requiere densidades similares.

IV. Diseño experimental

Se evaluaron tres algoritmos de clustering: K-means, DBSCAN y clustering jerárquico (Ward), sobre 3 730 observaciones distrito-nivel educativo. Los atributos fueron transformados mediante $\log(1+x)$ y estandarizados con Z-score.

Para K-means se evaluaron valores de K entre 2 y 8, utilizando inercia, Silhouette y Davies–Bouldin. Se seleccionó $K = 2$, con Silhouette de 0.265 y Davies–Bouldin de 1.465.

Para DBSCAN se evaluaron distintos valores de ε, manteniendo `min_samples` $= 10$. Con $\varepsilon = 1{,}06$ se identificó un cluster principal y 4.5 % de observaciones clasificadas como ruido.

En el clustering jerárquico se seleccionó Ward con $K = 2$, obteniendo Silhouette de 0.238 y Davies–Bouldin de 1.637.

V. Resultados preliminares

V-A. Comparación de algoritmos

Los mapas de calor permiten identificar dos perfiles principales:

K-means presenta mejores métricas internas que Ward, aunque la separación entre grupos es limitada. DBSCAN identifica principalmente un cluster y observaciones atípicas.

Selección del algoritmo: Se seleccionó K-means con $K = 2$ porque obtuvo un Silhouette superior al de Ward (0.265 frente

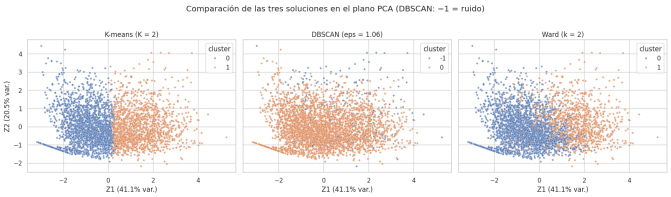


Figura 1: Comparación de K-means, DBSCAN y Ward mediante proyección PCA.

a 0.238) y un índice Davies–Bouldin menor (1.465 frente a 1.637), lo que indica una mejor separación relativa de los grupos.

Además, ambos métodos coincidieron en el 84.6 % de las asignaciones, mientras que DBSCAN identificó principalmente un único cluster y 4.5 % de observaciones como ruido.

Por ello, K-means ofrece la segmentación más adecuada entre las configuraciones evaluadas, aunque la separación entre clusters sigue siendo limitada.

V-B. Caracterización de los clusters

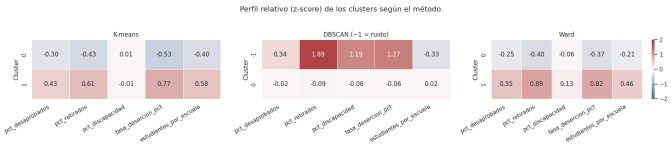


Figura 2: Mapas de calor de los perfiles relativos obtenidos mediante K-means, DBSCAN y Ward.

Interpretación: K-means y Ward distinguen perfiles con indicadores de salida escolar altos y bajos. En DBSCAN, las observaciones atípicas presentan mayores indicadores de retiro y deserción que el grupo principal.

- **Cluster 0 - Salida escolar baja:** presenta menores tasas de deserción (0.50 %), retiro (0.19 %) y desaprobación (2.68 %). Agrupa 2 201 observaciones.
- **Cluster 1 - Salida escolar alta:** registra mayores tasas de deserción (2.90 %), retiro (1.95 %) y desaprobación (5.64 %). Agrupa 1 529 observaciones.

La variable discapacidad presenta diferencias mínimas entre ambos grupos (1.86 % frente a 1.91 %), por lo que tiene menor capacidad para distinguir estos perfiles.

V-C. Distribución geográfica de los clusters

Como se observa en la Figura 3, el cluster de salida escolar alta comprende 345 distritos en primaria y 1 170 en secundaria. Esto evidencia una mayor presencia territorial del perfil de salida alta en secundaria.

V-D. Distribución espacial de la deserción

En primaria predominan tasas bajas, con valores elevados localizados principalmente en la selva. En secundaria, la distribución es más heterogénea e incluye distritos de la sierra y la costa norte.

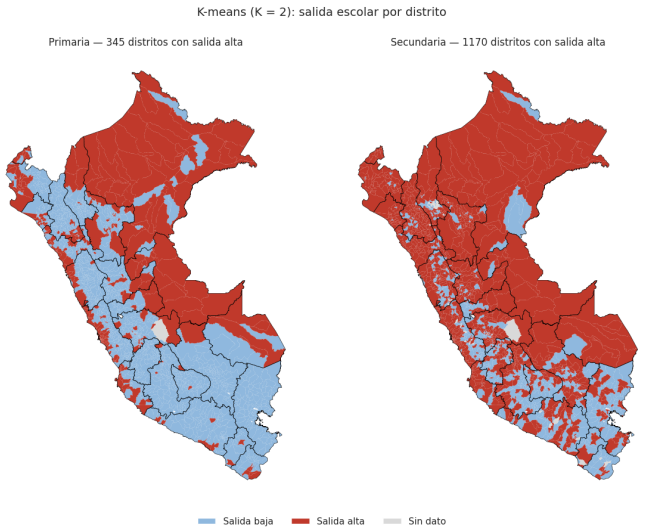
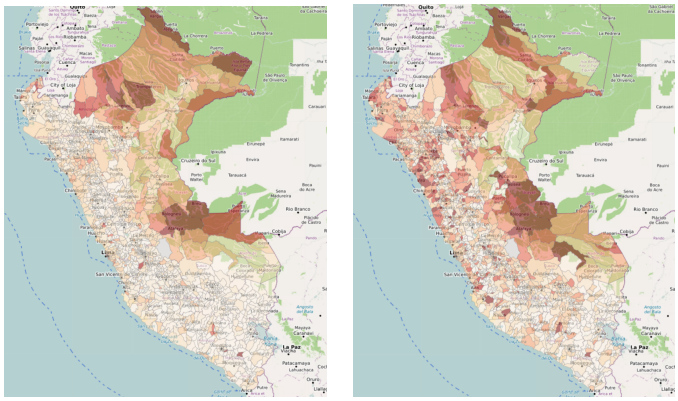


Figura 3: Distribución geográfica de los clusters K-means en primaria y secundaria.



(a) Primaria (b) Secundaria

Figura 4: Mapas coropléticos de la tasa de deserción por distrito, 2023–2024.

V-E. Distritos con mayor brecha de deserción

Los distritos con mayores brechas de deserción entre secundaria y primaria fueron Ataquero (Áncash), con 17.43 puntos porcentuales; Culebras (Áncash), con 12.51; y La Cuesta (La Libertad), con 11.36. Estos resultados evidencian diferencias importantes entre niveles educativos en determinados distritos.

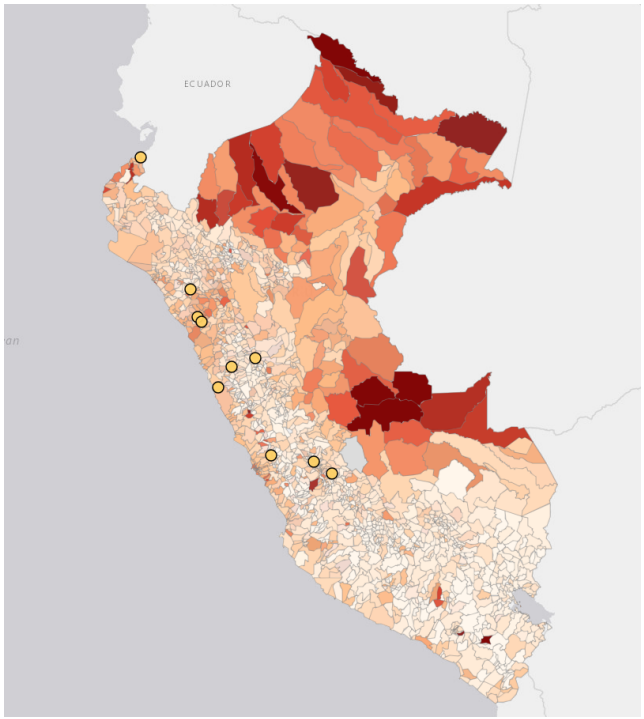


Figura 5: Diez distritos con mayor brecha de deserción entre secundaria y primaria.

VI. Problemas, limitaciones y trabajo pendiente

Los experimentos realizados permitieron identificar dos perfiles de salida escolar y analizar su distribución territorial. Sin embargo, se identificaron algunas limitaciones que deberán considerarse en la interpretación final.

Cuadro I: Limitaciones y acciones pendientes

Limitación	Acción pendiente
Sensibilidad de DBSCAN a los parámetros	Revisar las observaciones clasificadas como ruido.
Cobertura geográfica incompleta	Verificar distritos sin información o correspondencia geográfica.
Diferencias entre algoritmos	Contrastar las asignaciones de K-means y Ward.
Diferencias entre niveles educativos	Profundizar en la comparación de los perfiles de primaria y secundaria.

Trabajo pendiente para el Hito 4: Se consolidarán los resultados definitivos y la comparación de los algoritmos, profundizando en las diferencias entre los perfiles de salida escolar y su distribución territorial.

Asimismo, se desarrollará una discusión global de los hallazgos para responder la pregunta de investigación y formular las conclusiones y recomendaciones correspondientes.

Finalmente, se preparará la versión final del informe y se organizará el repositorio con el código, los datos y las instrucciones necesarias para reproducir los resultados.

Referencias

[1] Ministerio de Educación del Perú, "Datos abiertos del sector Educación: Padrón de instituciones educativas, matrícula y deserción escolar 2023–2024," MINEDU.

[2] F. Pedregosa et al., "Scikit-learn: Machine Learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.

[3] J. MacQueen, "Some Methods for Classification and Analysis of Multivariate Observations," *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*, pp. 281–297, 1967.

[4] M. Ester, H.-P. Kriegel, J. Sander and X. Xu, "A Density-Based Algorithm for Discovering Clusters in Large Spatial Databases with Noise," *Proceedings of KDD*, pp. 226–231, 1996.

[5] K. Jordahl et al., "GeoPandas: Python tools for geographic data," Zenodo, 2020.