Distritos del Perú con mayor salida escolar: un análisis de agrupamiento (2023–2024)

Rosalinda Salva, Cristina Nevado
Curso: Data Mining
Universidad del Pacífico
Docente: Soledad Espezúa Llerena

***Resumen*—Los promedios nacionales de matrícula escolar ocultan distritos donde muchos estudiantes dejan de matricularse de un año a otro. Este avance integra cuatro fuentes públicas del sector Educación (Padrón de IIEE, matrícula 2023 y deserción 2023–2024 en primaria y secundaria) en una matriz de 3 730 observaciones distrito × nivel descritas por cinco variables. Se aplicó *log1p* y z-score, y se compararon tres técnicas: K-means, DBSCAN y clustering jerárquico aglomerativo (Ward). K-means y Ward producen dos grupos similares (84.6 % de coincidencia): uno de salida escolar baja y otro de salida alta, con escuelas más grandes y mayor presencia de secundaria. DBSCAN forma un único grupo y solo detecta casos extremos. Los datos forman una nube continua, por lo que los resultados son una segmentación por perfiles. Silhouette y Davies-Bouldin quedan pendientes.**

***Index Terms*—data mining, clustering jerárquico, salida escolar, GeoPandas**

I. Introducción

El proyecto usa datos abiertos del MINEDU sobre matrícula y deserción en primaria y secundaria entre 2023 y 2024, por distrito [1]. **Problema.** Cada año, algunos estudiantes no vuelven a matricularse en ninguna escuela, lo que interrumpe su educación básica. Esto afecta de forma desigual a los distritos: el promedio nacional parece estable, pero oculta distritos donde la salida es mucho mayor. Hoy no es claro qué tipos de distritos tienen más salida, dónde se ubican ni si el problema pesa más en primaria o en secundaria, lo que dificulta decidir dónde intervenir primero. **Usuario o beneficiario.** El MINEDU, las Direcciones Regionales de Educación (DRE) y las UGEL, que deciden dónde destinar becas, transporte, tutorías y seguimiento de estudiantes en riesgo, y necesitan saber qué distritos y qué nivel priorizar. **Objetivo de análisis.** Agrupar los distritos según su perfil de salida escolar y comparar primaria con secundaria, para ubicar los de mayor salida. **Pregunta principal.** *¿Qué perfiles de distritos se distinguen según su salida escolar y dónde están los de mayor salida en cada nivel?*

II. Datos y representación final

Fuentes: Padrón de IIEE (aporta el ubigeo de cada escuela), matrícula 2023 y deserción 2023–2024 de primaria y secundaria, medida como cohorte (matriculados en 2023 que no volvieron a matricularse en 2024 en ninguna escuela del sistema). **Unidad de análisis:** distrito × nivel educativo (3 730 observaciones). **Variables principales:** % desaprobados, % retirados, % con discapacidad, tasa de deserción y estudiantes por escuela. **Representación final:** matriz de 3 730×5 sin nulos, con *log1p* y z-score para reducir la asimetría (sesgo de 1.88–3.94 a $-0{,}12$–1.38) y evitar que una variable domine la distancia. **Exclusiones:** identificadores, totales absolutos (se comparan tasas), % aprobados (colineal) y `nivel_bin`, usado solo para interpretar.

III. Metodología

Como no existe una clase que indique qué distritos son críticos, se usó agrupamiento no supervisado. Se compararon tres técnicas: **K-means** [3], que agrupa minimizando la varianza dentro de cada grupo; **clustering jerárquico con enlace Ward** [**?**], que no exige fijar el número de grupos de antemano y forma grupos compactos; y **DBSCAN** [4], que detecta zonas densas y marca el resto como ruido. Se ejecutaron con `scikit-learn` [2] sobre los datos reales, sin usar coordenadas ni `nivel_bin`; la ubicación geográfica solo se usó para mapear con GeoPandas [5].

Supuestos y limitaciones. Las tres técnicas usan distancia euclidiana, por lo que la escala importa; se prefirió z-score sobre Min-Max porque los valores extremos son reales y Min-Max comprimiría a la mayoría. K-means y Ward asumen grupos compactos y son sensibles a valores extremos; DBSCAN requiere densidades similares.

IV. Diseño experimental

Se evaluaron tres algoritmos de clustering: K-means, DBSCAN y clustering jerárquico (Ward), sobre 3 730 observaciones distrito-nivel educativo. Los atributos fueron transformados mediante $\log(1+x)$ y estandarizados con Z-score.

Para K-means se evaluaron valores de K entre 2 y 8, utilizando inercia, Silhouette y Davies–Bouldin. Se seleccionó $K = 2$, con Silhouette de 0.265 y Davies–Bouldin de 1.465.

Para DBSCAN se evaluaron distintos valores de ε, manteniendo `min_samples` $= 10$. Con $\varepsilon = 1{,}06$ se identificó un cluster principal y 4.5 % de observaciones clasificadas como ruido.

En el clustering jerárquico se seleccionó Ward con $K = 2$, obteniendo Silhouette de 0.238 y Davies–Bouldin de 1.637.

V. Resultados preliminares

V-A. Comparación de algoritmos

Los mapas de calor permiten identificar dos perfiles principales:

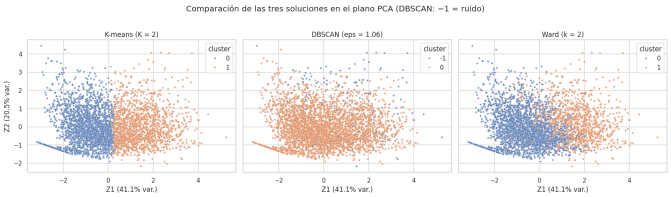


Figura 1: Comparación de K-means, DBSCAN y Ward mediante proyección PCA.

K-means presenta mejores métricas internas que Ward, aunque la separación entre grupos es limitada. DBSCAN identifica principalmente un cluster y observaciones atípicas.

Selección del algoritmo: Se seleccionó K-means ($K = 2$) por obtener mejores métricas que Ward: Silhouette superior al de Ward (0.265 frente a 0.238) y un índice Davies–Bouldin menor (1.465 frente a 1.637), lo que indica una mejor separación relativa de los grupos.

Además, ambos métodos coincidieron en el 84.6 % de las asignaciones, mientras que DBSCAN identificó principalmente un único cluster y 4.5 % de observaciones como ruido.

Por ello, K-means ofrece la segmentación más adecuada entre las configuraciones evaluadas, aunque la separación entre clusters sigue siendo limitada.

V-B. Caracterización de los clusters

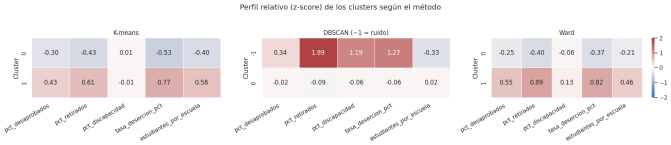


Figura 2: Mapas de calor de los perfiles relativos obtenidos mediante K-means, DBSCAN y Ward.

Interpretación: K-means y Ward distinguen perfiles con indicadores de salida escolar altos y bajos. En DBSCAN, las observaciones atípicas presentan mayores indicadores de retiro y deserción que el grupo principal.

- **Cluster 0 - Salida escolar baja:** presenta menores tasas de deserción (0.50 %), retiro (0.19 %) y desaprobación (2.68 %). Agrupa 2 201 observaciones.
- **Cluster 1 - Salida escolar alta:** registra mayores tasas de deserción (2.90 %), retiro (1.95 %) y desaprobación (5.64 %). Agrupa 1 529 observaciones.

La variable discapacidad presenta diferencias mínimas entre ambos grupos (1.86 % frente a 1.91 %), por lo que tiene menor capacidad para distinguir estos perfiles.

V-C. Distribución geográfica de los clusters

Como se observa en la Figura 3, el cluster de salida escolar alta comprende 345 distritos en primaria y 1 170 en secundaria. Esto evidencia una mayor presencia territorial del perfil de salida alta en secundaria.

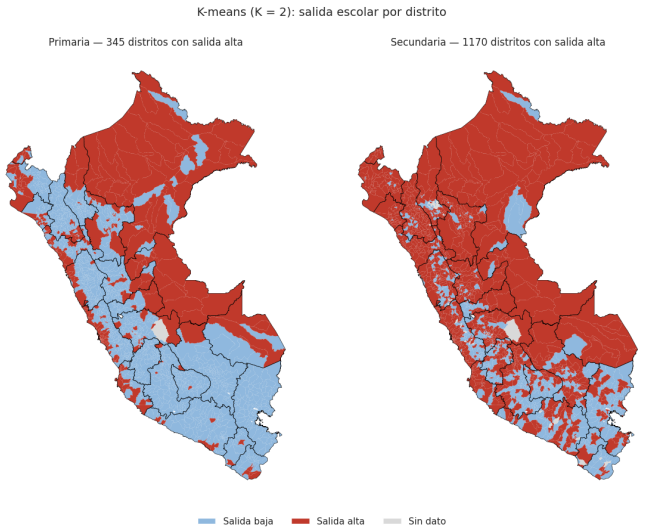
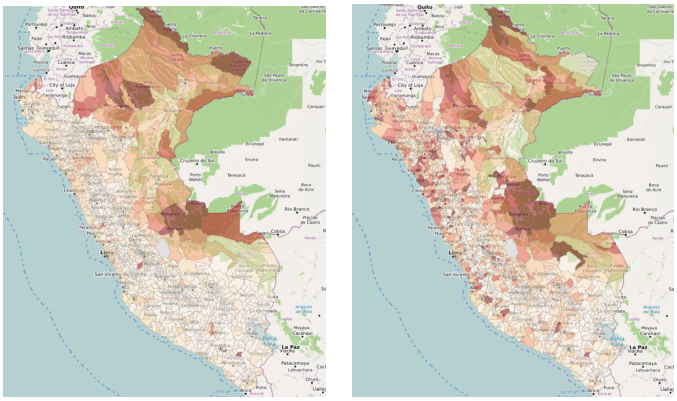


Figura 3: Distribución geográfica de los clusters K-means en primaria y secundaria.



(a) Primaria (b) Secundaria

Figura 4: Mapas coropléticos de la tasa de deserción por distrito, 2023–2024.

V-D. Distribución espacial de la deserción

En primaria predominan tasas bajas, con valores elevados localizados principalmente en la selva. En secundaria, la distribución es más heterogénea e incluye distritos de la sierra y la costa norte.

V-E. Distritos con mayor brecha de deserción

Los distritos con mayores brechas de deserción entre secundaria y primaria fueron Ataquero (Áncash), con 17.43 puntos porcentuales; Culebras (Áncash), con 12.51; y La Cuesta (La Libertad), con 11.36. Estos resultados evidencian diferencias importantes entre niveles educativos en determinados distritos.

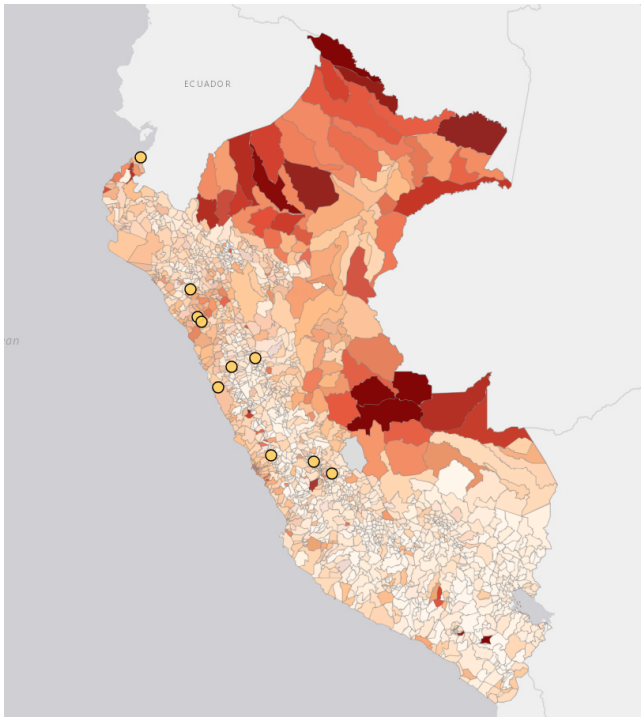


Figura 5: Diez distritos con mayor brecha de deserción entre secundaria y primaria.

VI. Problemas, limitaciones y trabajo pendiente

Los experimentos realizados permitieron identificar dos perfiles de salida escolar y analizar su distribución territorial. Sin embargo, se identificaron algunas limitaciones que deberán considerarse en la interpretación final.

Cuadro I: Limitaciones y acciones pendientes

Limitación	Acción pendiente
Sensibilidad de DBSCAN a los parámetros	Revisar las observaciones clasificadas como ruido.
Cobertura geográfica incompleta	Verificar distritos sin información o correspondencia geográfica.
Diferencias entre algoritmos	Contrastar las asignaciones de K-means y Ward.
Diferencias entre niveles educativos	Profundizar en la comparación de los perfiles de primaria y secundaria.

Trabajo pendiente para el Hito 4: Se consolidarán los resultados definitivos y la comparación de los algoritmos, profundizando en las diferencias entre los perfiles de salida escolar y su distribución territorial.

Asimismo, se desarrollará una discusión global de los hallazgos para responder la pregunta de investigación y formular las conclusiones y recomendaciones correspondientes.

Finalmente, se preparará la versión final del informe y se organizará el repositorio con el código, los datos y las instrucciones necesarias para reproducir los resultados.

Referencias

[1] Ministerio de Educación del Perú, "Datos abiertos del sector Educación: Padrón de instituciones educativas, matrícula y deserción escolar 2023–2024," MINEDU.

[2] F. Pedregosa et al., "Scikit-learn: Machine Learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.

[3] J. MacQueen, "Some Methods for Classification and Analysis of Multivariate Observations," *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*, pp. 281–297, 1967.

[4] M. Ester, H.-P. Kriegel, J. Sander and X. Xu, "A Density-Based Algorithm for Discovering Clusters in Large Spatial Databases with Noise," *Proceedings of KDD*, pp. 226–231, 1996.

[5] K. Jordahl et al., "GeoPandas: Python tools for geographic data," Zenodo, 2020.